

**UNIVERSITATEA „POLITEHNICA” din BUCUREȘTI**  
Facultatea de Electronică, Telecomunicații și Tehnologia Informației

Proiect

Ingineria Sistemelor cu Inteligență Artificială

Forest Fires – Random Forest

Pescaru Anamaria Andra

Grupa: 424A

Bucuresti 2022

## Scopul proiectului

Acest proiect are ca scop implementarea unui program care să prezică zonele arse de incendiile forestiere, în regiunea de nord-est a Portugaliei.

Aceasta este o problema de regresie pe care am rezolvat-o folosind metoda Random Forest cu 10 arbori.

## Datele inițiale ale proiectului

Pentru acest proiect s-au folosit datele de pe acest site:  
<https://archive.ics.uci.edu/ml/datasets/Forest+Fires> .

Setul de date conține 13 atribute :

1. X - coordonata spatiala x din harta parcului Montesinho : de la 1 la 9;
2. Y – coordonata spatiala y din harta parcului Montesinho : de la 2 la 9;
3. month – denumirea lunii dintr-un an : din “ianuarie” până în “decembrie”;
4. day – denumirea zilei dintr-o saptamana : de “luni” până “duminică”;
5. FFMC – FFMC index din sistemul FWI : de la 18.7 la 96.20;
6. DMC – DMC index din sistemul FWI : de la 1.1 la 291.3;
7. DC – DC index din sistemul FWI : de la 7.9 la 860.6;
8. ISI – ISI index din sistemul FWI : de la 0.0 la 56.10;
9. temp – temperatura în grade Celsius : de la 2.2 la 33.30;
10. RH - umiditatea relativa în % : de la 15.0 la 100;
11. wind – viteza vantului în km/h : de la 0.40 la 9.40;

12. rain – cantitatea de precipitatii mm/m2 : de la 0.0 la 6.4;
13. area – portiunea arsa dintr-o padure (in ha) : de la 0.0 la 1090.84;

## Etapele de construire a codului

1. Importăm librariile de care avem nevoie.

```
import numpy as np
import matplotlib.pyplot as plt
import pandas as pd
from sklearn import datasets, tree, ensemble
from sklearn.ensemble import BaggingRegressor
```

2. Extragem datele din fisierul csv .

```
datasets = pd.read_csv('forestfires.csv')
```

3. Pentru ca programul să funcționeze, este necesar ca in ‘datasets’ să existe doar date numerice.

- Am inlocuit denumirea lunilor de pe coloana ‘month’ cu numere de la 1 – 12 in urmatorul mod :

```
month_map = {"jan": 1, "feb": 2, "mar": 3, "apr": 4, "may": 5, "jun": 6, "jul": 7,
             "aug": 8, "sep": 9, "oct": 10, "nov": 11, "dec": 12}
datasets['month'] = datasets['month'].map(month_map)
```

- Am inlocuit denumirea zilelor saptamanii de pe coloana ‘day’ cu numere de la 1 – 7 in urmatorul mod:

```
day_map = {"mon": 1, "tue" : 2 , "wed" : 3, "thu" : 4 , "fri" : 5, "sat" : 6, "sun" : 7}
datasets['day'] = datasets['day'].map(day_map)
```

4. Am construit o matrice in care am introdus datele din 'datasets'.

```
datasets = datasets.to_numpy()
datasets = np.array(datasets)
```

5. Impărțim datele.

Setul de date este format din 517 eșantioane, adica matricea noastra este compusa din 517 linii si 13 coloane.

Impărțirea datelor se realizează astfel:

- 75% din date sunt folosite pentru setul de antrenare

```
data_train = datasets[: 387, 0 : 13]
etichete_train = datasets[0 : 387, 12]
```

- 25% din date sunt folosite pentru setul de testare

```
data_test = datasets[387 : , 0 : 13]
etichete_test = datasets[387 : , 12]
```

Observații:

- Datele care trebuie etichetate in această problem sunt datele care se afla pe ultima coloană.
- 'data\_train' si 'data\_test' sunt niste matrici.
- 'etichete\_train' si 'etichete\_test' sunt niste vectori.

6. Am construit un vector care sa retina procentul "in-bag" (25%, 50%, 85%) si un vector care sa retina numarul de dimensiuni alese intr-un nod (10%, 50% 80%).

```
in_bag = [0.25, 0.5, 0.85 ];  
dimensiuni_nod = [0.1, 0.5, 0.8];
```

7. Am creat si antrenat arborele de regresie prin varierea concomitenta a procentului 'in-bag' si a dimensiunii nodului folosind doua for – uri.

```
for i in range(3):  
    for j in range(3):  
        regr = BaggingRegressor(n_estimators = 10, max_samples = in_bag[i], max_features = dimensiuni_nod[j], random_state=0)  
        regr_fit = regr.fit(data_train, etichete_train)  
  
        predictii = regr.predict(data_test);  
        suma = 0;  
        for k in range(0, len(etichete_test)):  
            suma += (predictii[k] - etichete_test[k]) ** 2;  
  
        print('Eroarea patratica medie pentru in_bag ', in_bag[i], ' si dimensiunea nodului de', dimensiuni_nod[j], ' este ', suma/len(etichete_test), '\n');
```

#### Observatii:

- Antrenarea s-a realizat cu ajutorul functiei 'fit' care a primit ca parametrii datele din cele doua seturi de antrenare ( data\_train si etichete\_test).
- Predictiile s-au realizat cu ajutorul functiei 'predict' care a primit ca parametrii datele din "data\_test".
- Datorita faptului ca este o problema de regresie, am calculat eroarea patratica medie cu ajutorul unui for.

Programul afiseaza pe rand, pentru perechea :

- Procent in-bag de 0.25 si dimensiune nod de 0.1:

```
Eroarea patratica medie pentru in_bag 0.25 si dimensiunea nodului de 0.1 este 4644.406702252589
```

- Procent in-bag de 0.25 si dimensiune nod de 0.5:

```
Eroarea patratica medie pentru in_bag 0.25 si dimensiunea nodului de 0.5 este 2267.6379994999975
```

➤ Procent in-bag de 0.25 si dimensiune nod de 0.8:

```
Eroarea patratica medie pentru in_bag 0.25 si dimensiunea nodului de 0.8 este 1333.7244451769236
```

➤ Procent in-bag de 0.5 si dimensiune nod de 0.1:

```
Eroarea patratica medie pentru in_bag 0.5 si dimensiunea nodului de 0.1 este 4608.727481039542
```

➤ Procent in-bag de 0.5 si dimensiune nod de 0.5:

```
Eroarea patratica medie pentru in_bag 0.5 si dimensiunea nodului de 0.5 este 1948.3318764260675
```

➤ Procent in-bag de 0.5 si dimensiune nod de 0.8:

```
Eroarea patratica medie pentru in_bag 0.5 si dimensiunea nodului de 0.8 este 846.6002425769229
```

➤ Procent in-bag de 0.85 si dimensiune nod de 0.1:

```
Eroarea patratica medie pentru in_bag 0.85 si dimensiunea nodului de 0.1 este 4652.160440777733
```

➤ Procent in-bag de 0.85 si dimensiune nod de 0.5:

```
Eroarea patratica medie pentru in_bag 0.85 si dimensiunea nodului de 0.5 este 1939.8552585713676
```

➤ Procent in-bag de 0.85 si dimensiune nod de 0.8:

```
Eroarea patratica medie pentru in_bag 0.85 si dimensiunea nodului de 0.8 este 392.25324046538447
```

